Relatório técnico do Tech Challenge Fase 1

Diagnóstico de diabetes com machine learning

Marcelo Raimundo de Jesus, Pós Tech IA para Devs, FIAP, Grupo 53

1. O problema

A proposta do Tech Challenge era criar uma solução de IA que ajudasse médicos a fazer diagnóstico. Escolhi trabalhar com diabetes, que é um problema de classificação binária. A partir de dados clínicos simples, o modelo diz se a paciente tem ou não tem diabetes.

O objetivo não é substituir o médico. A ideia é ter uma ferramenta de triagem que aponte quem merece um olhar mais cuidadoso e um exame confirmatório. Por isso, desde o começo, defini que o erro mais grave seria deixar passar uma paciente com diabetes, e isso guiou a escolha das métricas.

Para organizar o trabalho segui as etapas do CRISP-DM que vimos em Fundamentos de IA. Entender o problema, entender os dados, preparar, modelar, avaliar e discutir a implantação.

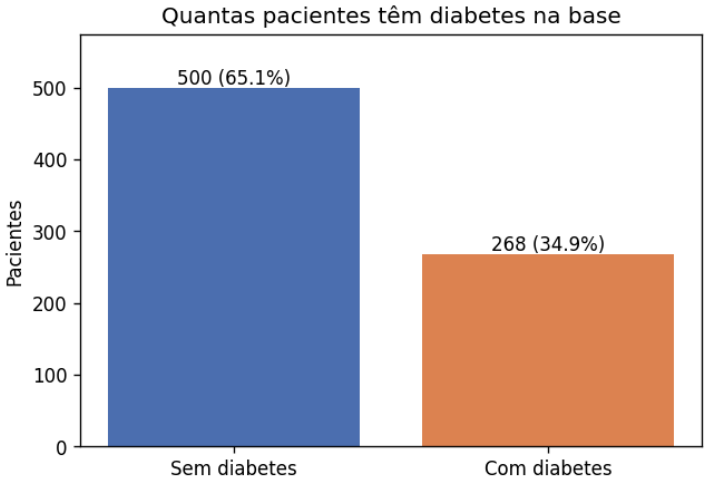
O código está no repositório do GitHub, com o notebook da análise, um script que roda tudo do zero, o Dockerfile e o README com as instruções.

2. A base de dados

Usei a Pima Indians Diabetes, indicada no enunciado. Ela tem 768 pacientes, todas mulheres com 21 anos ou mais da população Pima, e as seguintes variáveis.

Variável	O que é
Pregnancies	Número de gestações
Glucose	Glicose no teste oral de tolerância de 2 horas
BloodPressure	Pressão diastólica (mm Hg)
SkinThickness	Dobra cutânea do tríceps (mm)
Insulin	Insulina sérica de 2 horas
BMI	Índice de massa corporal
DiabetesPedigreeFunction	Indicador de histórico familiar
Age	Idade em anos
Outcome	1 com diabetes, 0 sem diabetes

A base não tem linhas duplicadas nem valores nulos declarados. O alvo é desbalanceado, com 500 pacientes sem diabetes (65,1%) e 268 com diabetes (34,9%). Isso quer dizer que um modelo que chuta sempre “sem diabetes” já acerta 65%, e é por isso que a acurácia sozinha não serve para avaliar este problema.



Distribuição do alvo

3. Preparação dos dados

3.1 Zeros que são dado faltando

No describe apareceu o principal problema da base. Cinco variáveis têm valor mínimo igual a zero, o que é impossível numa pessoa viva. Esses zeros são dado faltando disfarçado.

Variável	Zeros	Percentual
Insulina	374	48,7%
Dobra cutânea	227	29,6%
Pressão diastólica	35	4,6%
IMC	11	1,4%
Glicose	5	0,7%

Apagar essas linhas jogaria fora 376 pacientes, quase metade da base. Por isso troquei os zeros por vazio (NaN) e preenchi com a **mediana**, que sofre menos com valores extremos do que a média. Gestações igual a zero é um valor real e ficou de fora da troca.

3.2 Sem vazamento de informação

A mediana e a padronização foram colocadas **dentro do Pipeline do scikit-learn**. Assim elas são calculadas só com os dados de treino de cada dobra da validação cruzada e aplicadas depois no que o modelo não viu. Se eu calculasse a mediana na base inteira antes de separar, o teste estaria contaminando o treino, que é um erro que aparece em alguns notebooks das aulas e que eu quis evitar.

3.3 Valores extremos

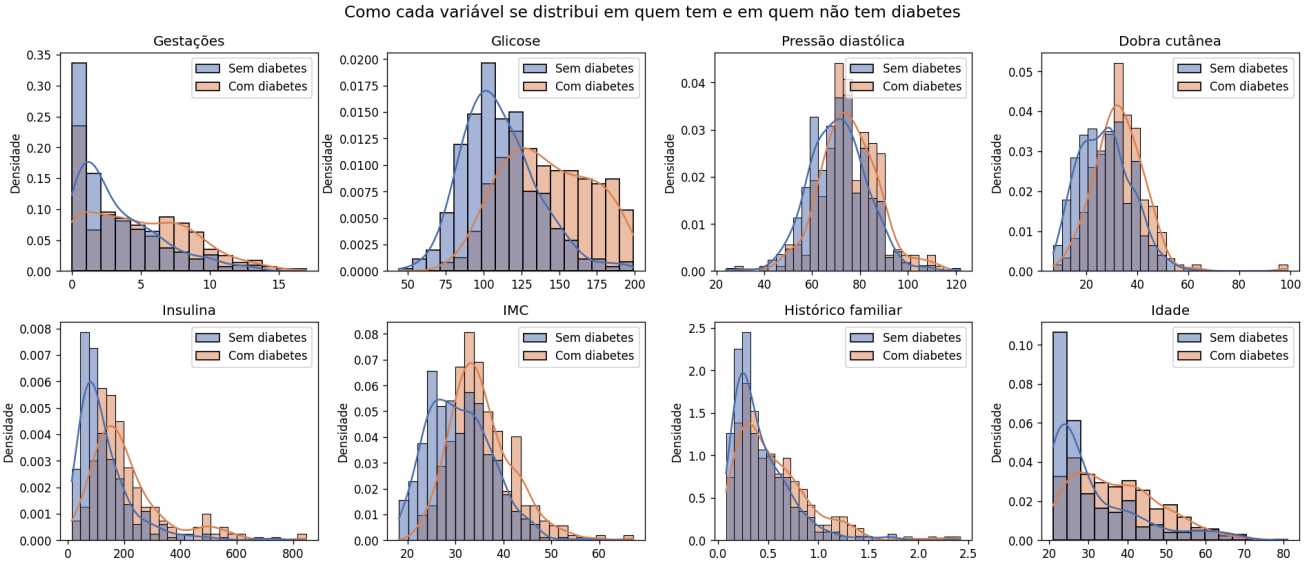
Insulina e dobra cutânea têm valores bem altos. Não removi esses pontos porque são clinicamente possíveis e a base já é pequena. Para a Regressão Logística usei o StandardScaler, e a Random Forest não precisa de escala porque as árvores só comparam valores.

3.4 Variáveis categóricas

Todas as variáveis da base são numéricas, então não foi preciso usar one-hot encoding nem label encoding.

4. Análise exploratória

Comparando as medianas dos dois grupos, quem tem diabetes tem glicose bem mais alta (140 contra 107), IMC maior (34,3 contra 30,1), é mais velha (36 contra 27 anos) e teve mais gestações (4 contra 2).

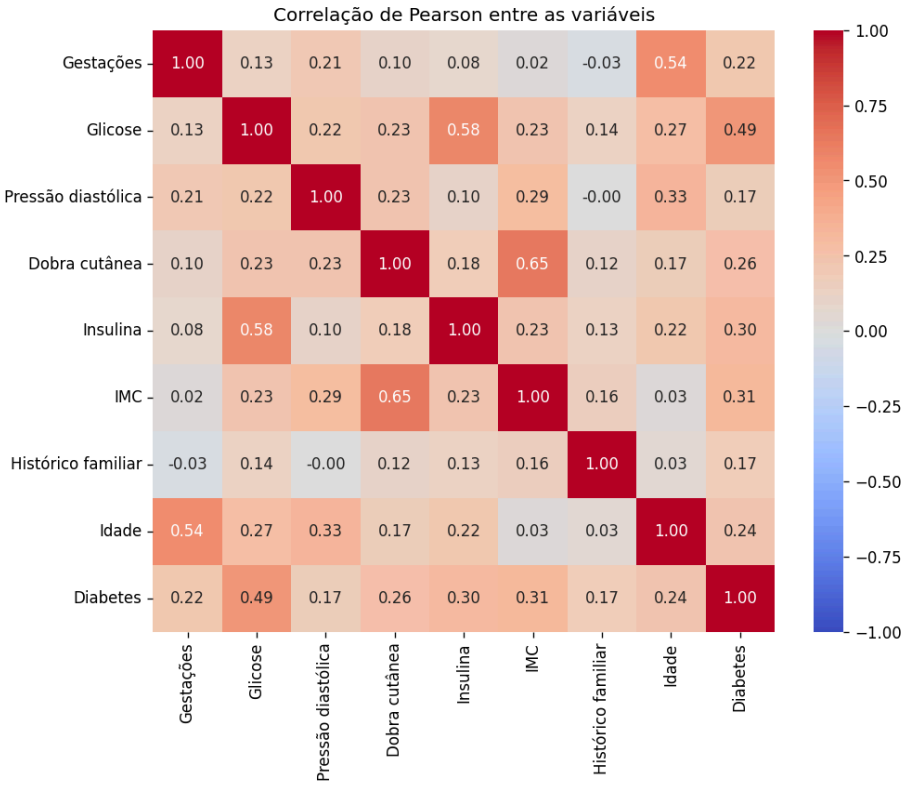


Distribuição de cada variável por grupo

A glicose é a variável que mais separa os grupos. IMC, idade e gestações também deslocam a curva, mas com muito mais mistura entre quem tem e quem não tem diabetes.

4.1 Correlação

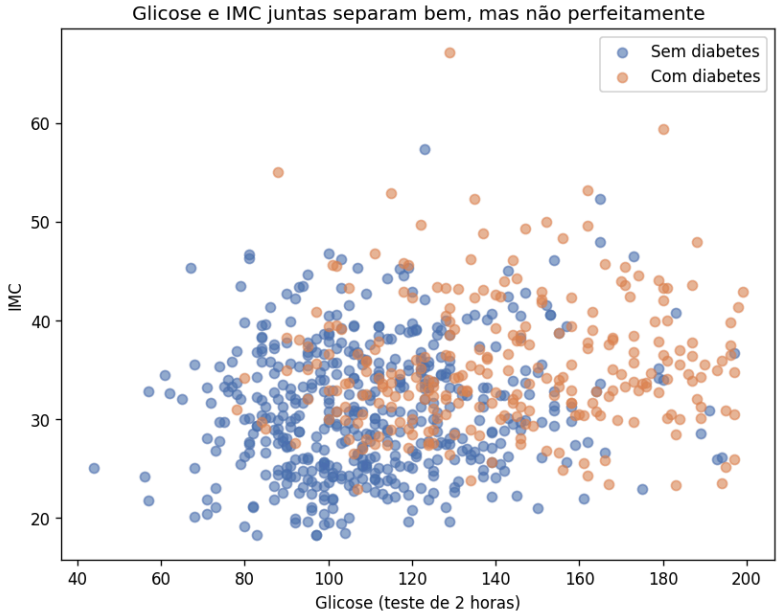
Calculei a correlação de Pearson entre todas as variáveis.



Correlação de Pearson

Com o diagnóstico, a glicose tem a correlação mais forte (0,49), seguida de IMC (0,31) e insulina (0,30). Entre as variáveis, idade e gestações andam juntas (0,54), assim como IMC e dobra cutânea (0,65) e glicose e insulina (0,58). Nenhuma correlação é tão alta a ponto de obrigar a remover variáveis.

Correlação não é causa. Ela mostra o que anda junto, mas não prova que uma variável provoca a outra.



Glicose e IMC por grupo

O gráfico de glicose com IMC resume bem o desafio. As duas juntas separam boa parte das pacientes, mas sobra uma região grande de mistura no meio. É ali que o modelo vai errar.

5. Modelagem

5.1 Separação dos dados

Separei 20% das pacientes para teste (154) e 80% para treino (614), mantendo a proporção de diabetes nos dois lados com `stratify`. Fixei `random_state=42` para que qualquer pessoa chegue nos mesmos números.

O teste ficou guardado e foi usado **uma única vez**, no final. Toda escolha de modelo, de hiperparâmetro e de limiar foi feita com validação cruzada estratificada de 5 dobras dentro do treino. Assim o treino e a validação acontecem sempre em partes diferentes dos dados, e o teste continua sendo uma prova que o modelo nunca viu.

5.2 Modelos escolhidos

Modelo	Por que escolhi
Modelo base (DummyClassifier)	Chuta sempre a classe mais comum. É o piso que qualquer modelo precisa superar
Regressão Logística	Simples, rápida e fácil de explicar, porque cada variável recebe um peso. Precisa de escala
Random Forest	Várias árvores de decisão que votam juntas. Pega relações não lineares, não precisa de escala e combina bem com SHAP

5.3 Hiperparâmetros

Usei o GridSearchCV com validação cruzada estratificada, otimizando o **F1**, que equilibra precisão e recall.

Modelo	Grade testada	Escolhido
Regressão Logística	C em 0,01, 0,1, 1, 10 e class_weight None ou balanced	C 0,1 e class_weight balanced
Random Forest	200 ou 400 árvores, profundidade 4, 6, 8 ou livre, mínimo por folha 1, 5 ou 10, class_weight None ou balanced	400 árvores, profundidade 4, mínimo de 10 por folha, class_weight balanced

Nos dois modelos o `class_weight="balanced"` venceu. Ele dá mais peso às pacientes com diabetes durante o treino e compensa o desequilíbrio da base. Na Random Forest venceram árvores rasas e folhas com pelo menos 10 pacientes, o que evita decorar a base de treino. Testei também otimizar direto pelo recall e os hiperparâmetros escolhidos foram os mesmos.

6. Avaliação

6.1 Qual métrica importa

Termo	No nosso caso
Verdadeiro positivo	Tem diabetes e o modelo apontou
Falso negativo	Tem diabetes e o modelo **não** apontou. É o erro mais grave
Falso positivo	Não tem diabetes e o modelo apontou. Gera um exame a mais
Verdadeiro negativo	Não tem diabetes e o modelo não apontou

O falso negativo é uma paciente doente que vai para casa sem acompanhamento. Por isso o **recall da classe com diabetes** é a métrica principal. O F1 entra para não deixar a precisão despencar, porque falso positivo demais sobrecarrega o médico. A ROC AUC mostra se o modelo ordena bem as pacientes por risco, e a acurácia fica só como referência.

6.2 Validação cruzada no treino

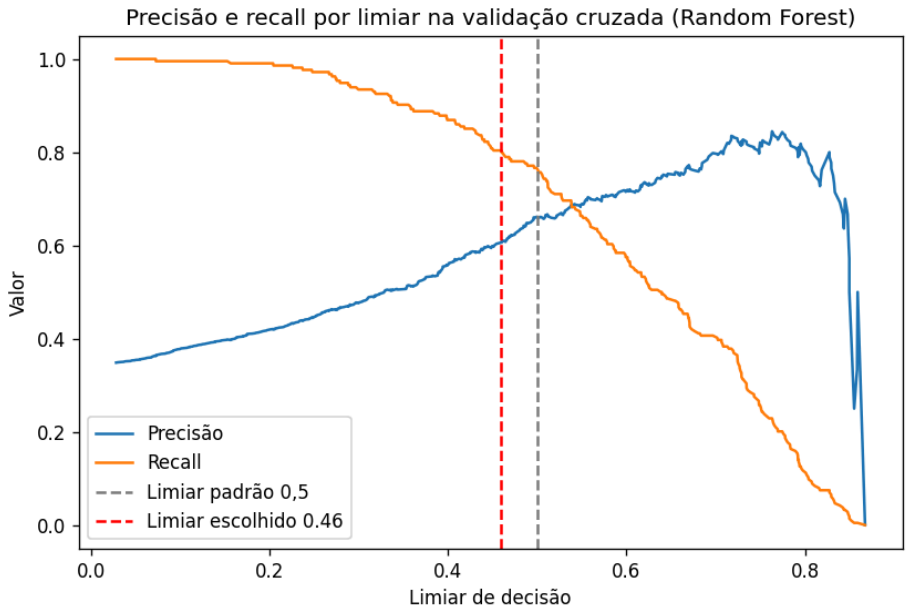
Média e desvio das 5 dobras.

Modelo	Acurácia	Precisão	Recall	F1	ROC AUC
Modelo base	0,651 ± 0,002	0,000	0,000	0,000	0,500
Regressão Logística	0,767 ± 0,008	0,651 ± 0,020	0,720 ± 0,050	0,682 ± 0,017	0,845 ± 0,013
Random Forest	0,780 ± 0,015	0,662 ± 0,029	0,762 ± 0,017	0,707 ± 0,010	0,840 ± 0,020

Os dois modelos passam bem do modelo base. A Random Forest fica à frente em recall e F1 e é mais estável no recall (desvio de 0,017 contra 0,050). Já a ROC AUC dos dois é praticamente igual, com diferença menor que o desvio entre as dobras.

6.3 Ajuste do limiar

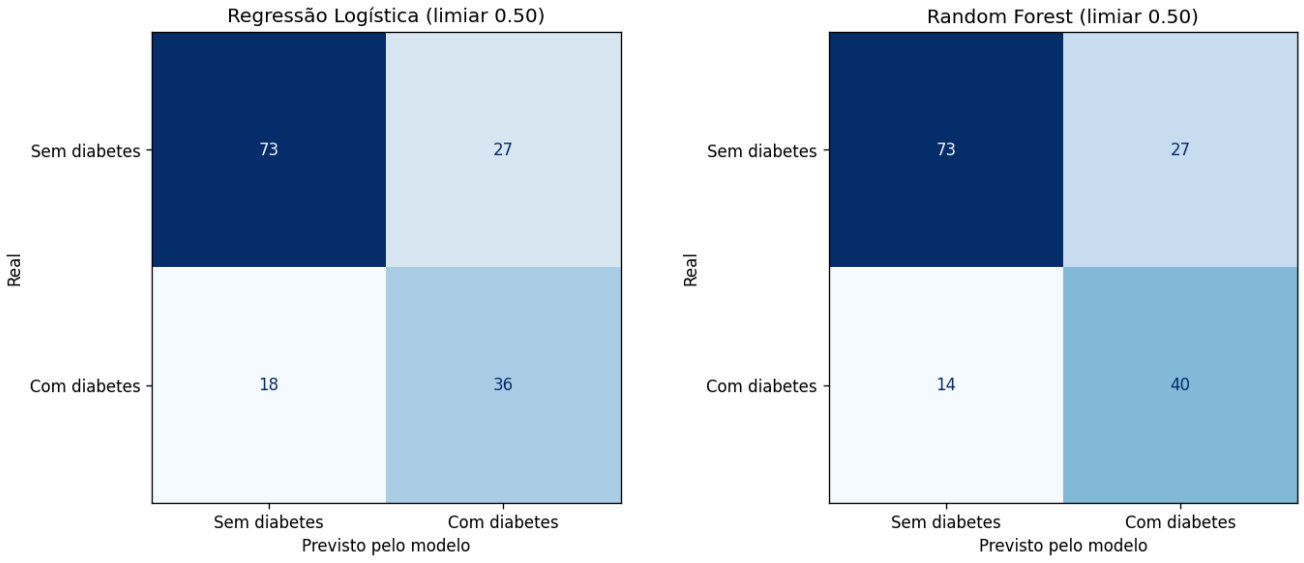
Por padrão o modelo aponta “com diabetes” quando a probabilidade passa de 0,5. Como o recall é a prioridade, procurei um limiar mais baixo para a Random Forest. Usei as probabilidades da validação cruzada do treino, nunca o teste, e escolhi o limiar com a maior precisão possível garantindo recall de pelo menos 80%. O resultado foi **0,46**.



Precisão e recall por limiar

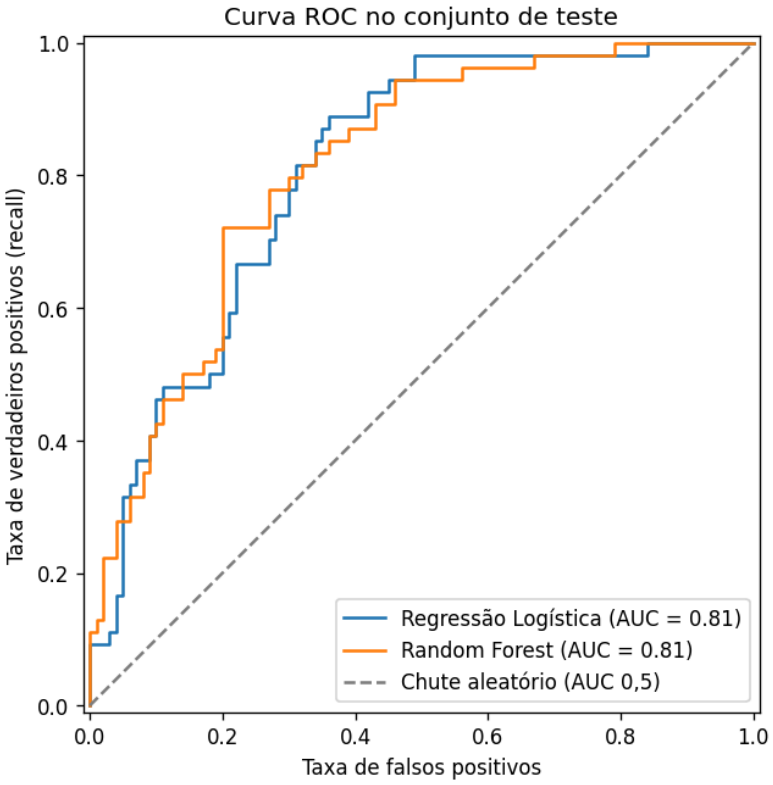
6.4 Resultado no teste

Modelo	Limiar	Acurácia	Precisão	Recall	F1	ROC AUC
Regressão Logística	0,50	0,708	0,571	0,667	0,615	0,810
Random Forest	0,50	0,734	0,597	0,741	0,661	0,814
Random Forest	0,46	0,721	0,573	**0,796**	0,667	0,814



Matrizes de confusão no teste

Das 54 pacientes com diabetes do teste, a Regressão Logística encontrou 36 e a Random Forest 40. Com o limiar ajustado a Random Forest chegou a 43, em troca de 5 falsos positivos a mais.



Curva ROC no teste

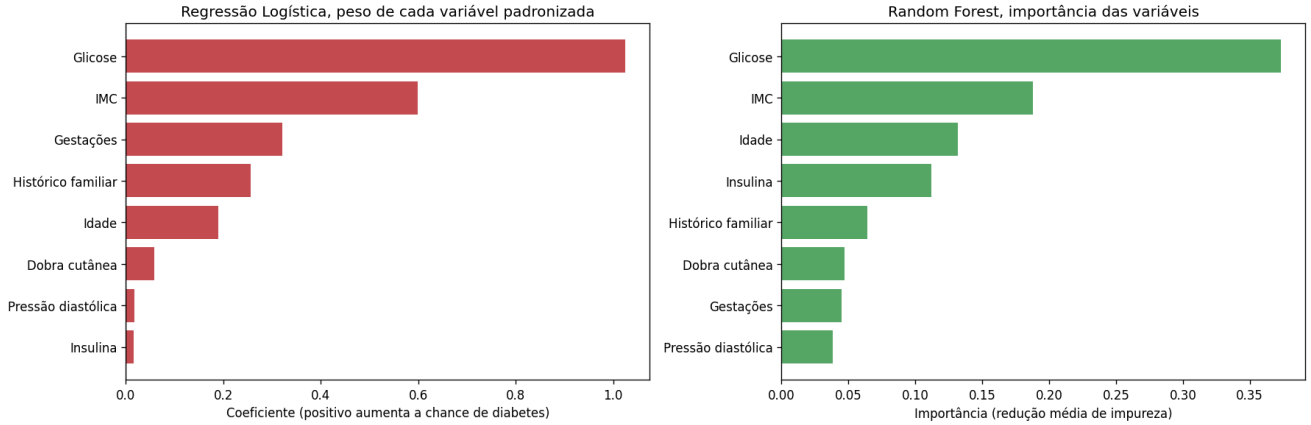
As duas curvas ROC ficam bem acima da diagonal do chute aleatório e muito próximas entre si, o que confirma o que a validação cruzada já mostrava.

Os números do teste ficaram um pouco abaixo da validação cruzada. Isso é esperado com só 154 pacientes, em que cada paciente com diabetes vale quase 2 pontos de recall. Por isso tomei as decisões olhando a média e o desvio da validação cruzada e usei o teste só para confirmar.

Modelo escolhido. Random Forest com limiar 0,46, por ter o maior recall com F1 e ROC AUC iguais ou melhores. A Regressão Logística continua sendo uma ótima opção quando a prioridade for explicar cada peso de forma simples.

7. Interpretação dos modelos

7.1 Pesos e importância das variáveis

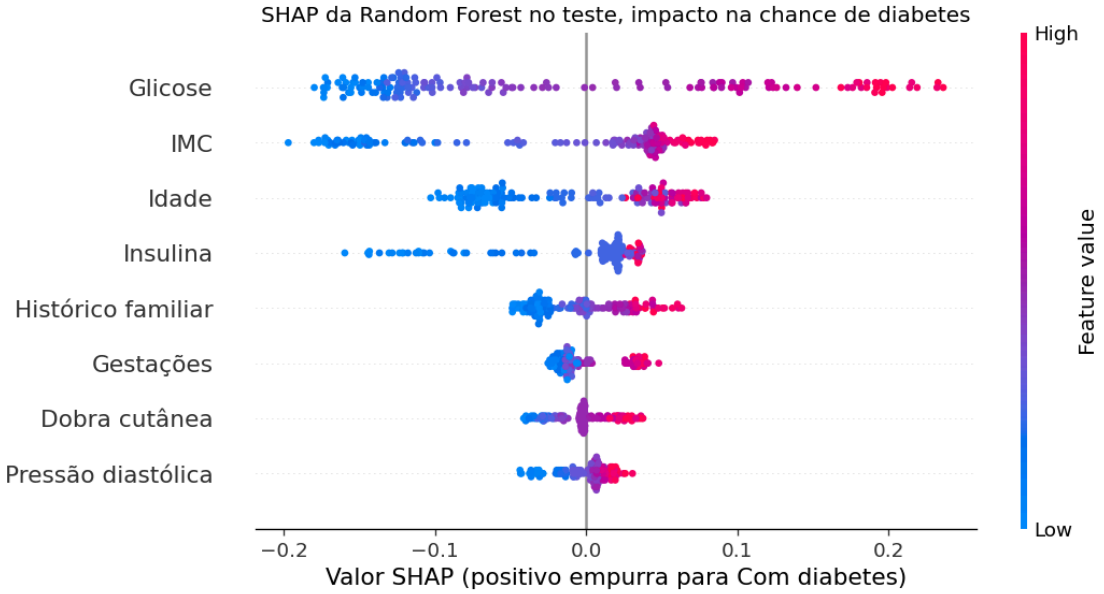


Coeficientes e importância das variáveis

Os dois modelos concordam no principal. **Glicose** é de longe a variável mais importante, seguida de **IMC** e **idade**. Na Regressão Logística, a razão de chances mostra que cada desvio padrão a mais de glicose multiplica a chance de diabetes por cerca de 2,8, e o IMC por cerca de 1,8.

Para a Random Forest conferi a importância por impureza com a importância por permutação no teste, que mede quanto a ROC AUC cai quando embaralho cada variável. As duas mostram a mesma ordem nas três primeiras posições.

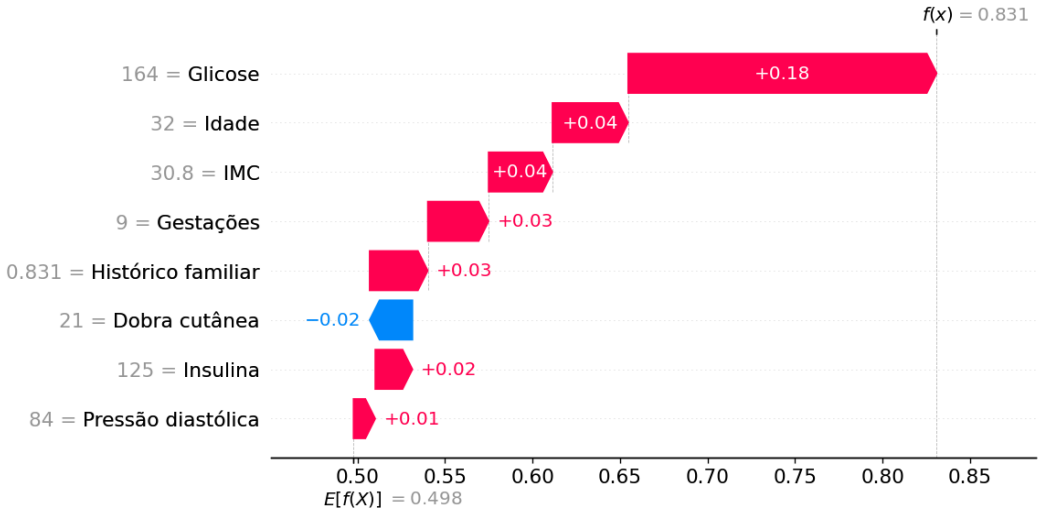
7.2 SHAP



SHAP da Random Forest

No gráfico do SHAP cada ponto é uma paciente do teste. A cor mostra o valor da variável e a posição mostra se ela empurrou a previsão para “com diabetes” (direita) ou para “sem diabetes” (esquerda). Glicose alta, IMC alto e idade maior empurram para a direita, que é

exatamente o que a medicina espera. Isso dá confiança de que o modelo aprendeu um padrão que faz sentido, e não uma coincidência da base.



Explicação de uma paciente

O SHAP também explica uma paciente por vez. Nesse exemplo o modelo partiu da média (cerca de 0,50) e chegou a 0,83 de probabilidade, puxado principalmente pela glicose de 164. É esse tipo de explicação que permite ao médico conferir e questionar o modelo.

8. Discussão crítica

Dá para usar na prática? Como apoio à triagem, sim. O modelo pode ajudar a priorizar quem deve fazer exames confirmatórios. Como diagnóstico sozinho, não. O médico tem a palavra final.

Os limites que precisam ficar claros são estes.

- **População específica.** A base tem só mulheres Pima com 21 anos ou mais. Não dá para garantir o mesmo resultado em homens, em outras etnias ou em grupos com metabolismo diferente, como pessoas que fizeram cirurgia bariátrica.
- **Tipo de exame.** A glicose da base é do teste oral de 2 horas, não a de jejum. Usar o modelo com glicose de jejum seria aplicar fora do que ele aprendeu.
- **Dados faltando.** Quase metade dos valores de insulina era faltante. A mediana preenche o buraco, mas não traz a informação real.
- **Ainda erra.** Mesmo com o limiar ajustado, o modelo deixou passar 11 das 54 pacientes com diabetes no teste. Por isso ele não pode ser o único filtro.
- **Base pequena e antiga.** São 768 pacientes. Antes de qualquer uso real seria preciso validar com dados atuais da população em que o modelo vai rodar e acompanhar o desempenho ao longo do tempo, porque os dados mudam (data drift).

9. Como reproduzir

Tudo roda com Docker.

```
docker build -t tech-challenge-fase1 .
docker run --rm tech-challenge-fase1
```

O README do repositório explica também como salvar os gráficos na sua máquina, como abrir o notebook pelo Docker e como rodar sem Docker. As versões das bibliotecas estão fixas no `requirements.txt` e todas as divisões usam `random_state=42`, então os números deste relatório se repetem em qualquer máquina.

10. Conclusão

Consegui montar um modelo que encontra cerca de 8 em cada 10 pacientes com diabetes, com ROC AUC de 0,81 no teste, usando só dados clínicos simples. Mais do que o número, o que me importou foi o caminho. Tratar os zeros como dado faltando, não vazar informação do teste, escolher a métrica pelo custo do erro e conseguir explicar cada previsão. O modelo mostra que dá para usar machine learning como apoio na saúde, desde que fique claro até onde ele vai e que a decisão final continua sendo do médico.